大規模アーカイブアクセスを対象とした データインテンシブサービスの提案

(独)情報通信研究機構 田仲 正弘,村上 陽平,是津 耕司

背景

- ▶ 計算機が扱うデータ規模が急速に拡大
 - ▶ Webページ, システム利用ログ, センサ, etc.
 - ▶ 様々な組織が資産として蓄積
- 大規模アーカイブの例:
 - WDS (World Data System)
 - 気象・地理などの各種のサイエンスデータのデータセット
 - ▶ WDSの一部のデータを提供するシステムPANGAEAでは60万データ セット(35PB)が登録
 - ▶ 情報分析システムWISDOM(NICT)
 - ▶ 自然言語処理ベースの情報分析を目的としてWeb文書を蓄積
 - ▶ 約20億規模, 総計200TB

研究の動機 大規模アーカイブへのアクセスの提供

- 様々な組織が大規模アーカイブをその成果として公開したがっている
 - ▶ 多くのユーザが使える形態で公開
 - ▶ 他の複数のアーカイブと連携利用

▶課題

- データが大きく、一度全てを取得してから処理することが不可能なため、用途が限られる
- ▶ データ形式・提供形態が多様で、連携・横断的利用が困難

事例: 大規模Webアーカイブアクセス

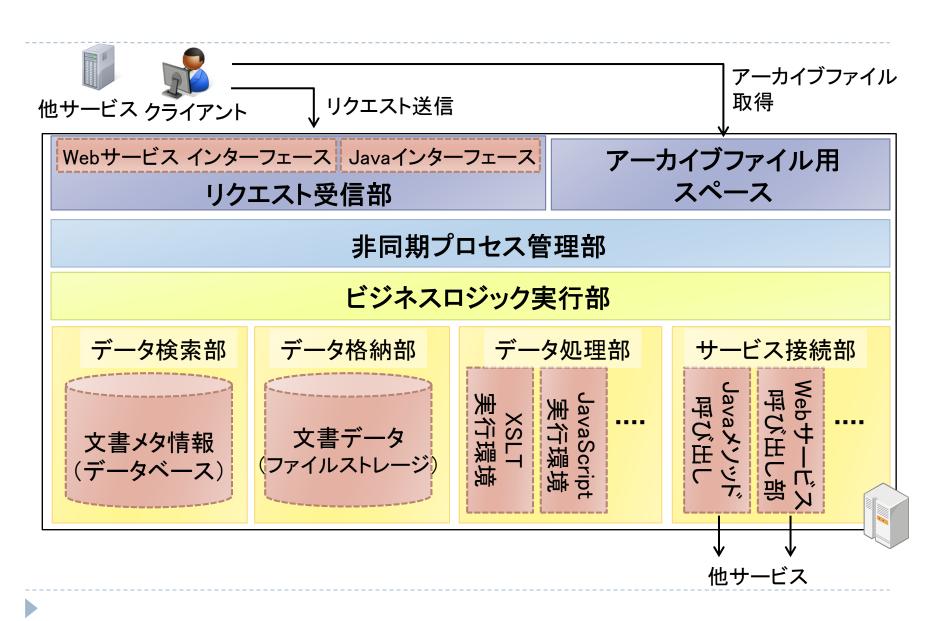
- ▶ 20億規模のWeb文書を70台のサーバに格納
 - ▶ 従来は特定の分析専用. データ検索・取得APIなし.
 - ▶ 今後, 所内の研究グループ向け, 一般向けに対象を広げる

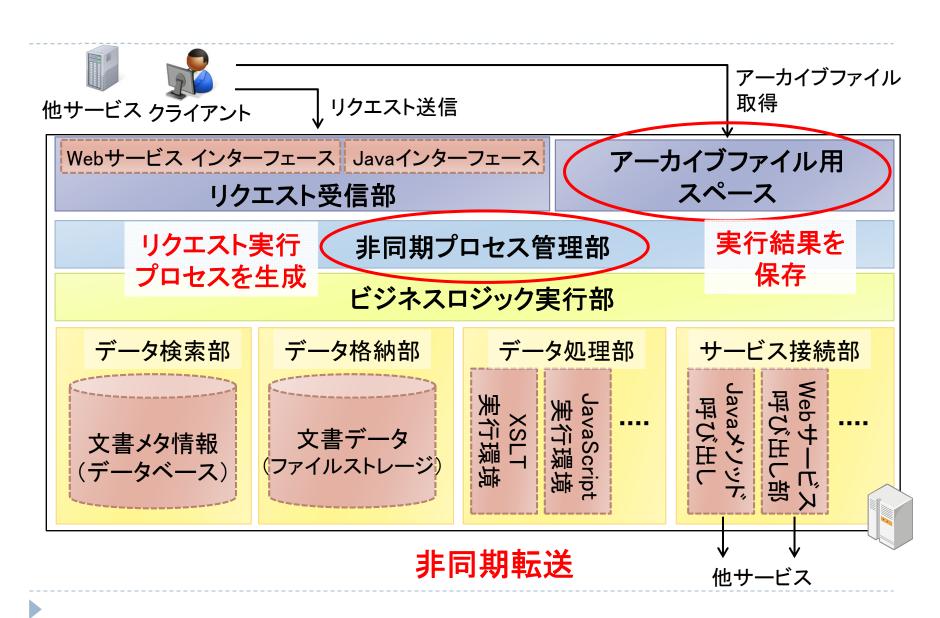
> 課題

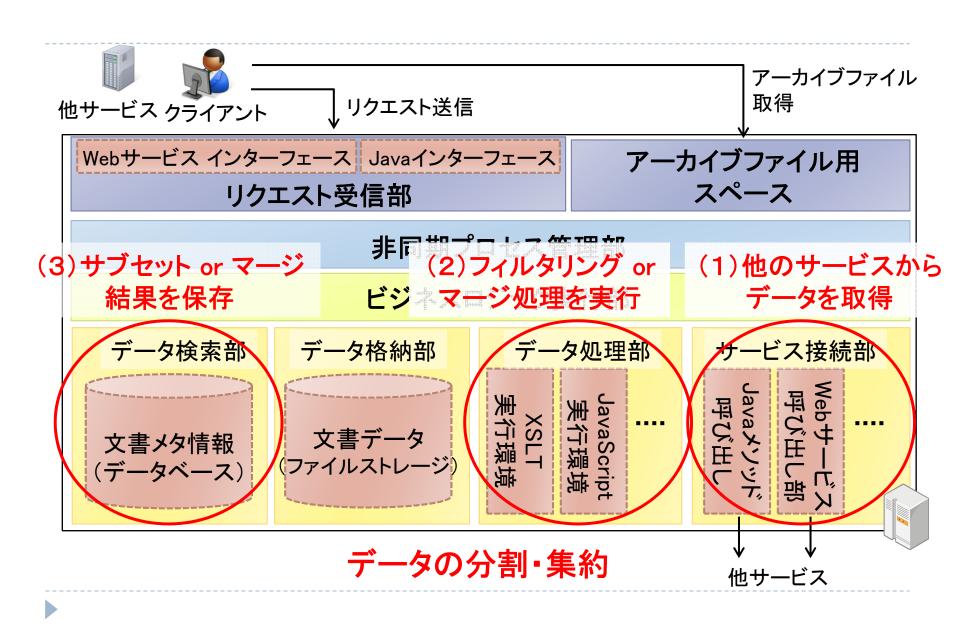
- ▶ 全データのネットワーク転送に2ヶ月を要する
 - ▶ 分析処理は自然言語処理の研究グループのマシンに移行して実行
 - ▶ その間データを必要とする研究の開始が遅れる
- データが冗長
 - ▶ 解析データによってサイズが10倍になり,帯域を圧迫
 - ほとんどのユーザは必要ない
- ▶ 検索方式に制限
 - ▶ URLベースの検索が実質不可能
 - ▶ 従来の利用は特定の分析処理に限定され、検索が不要だった
- → レガシーなシステムを疎結合な汎用コンポーネントとして提供

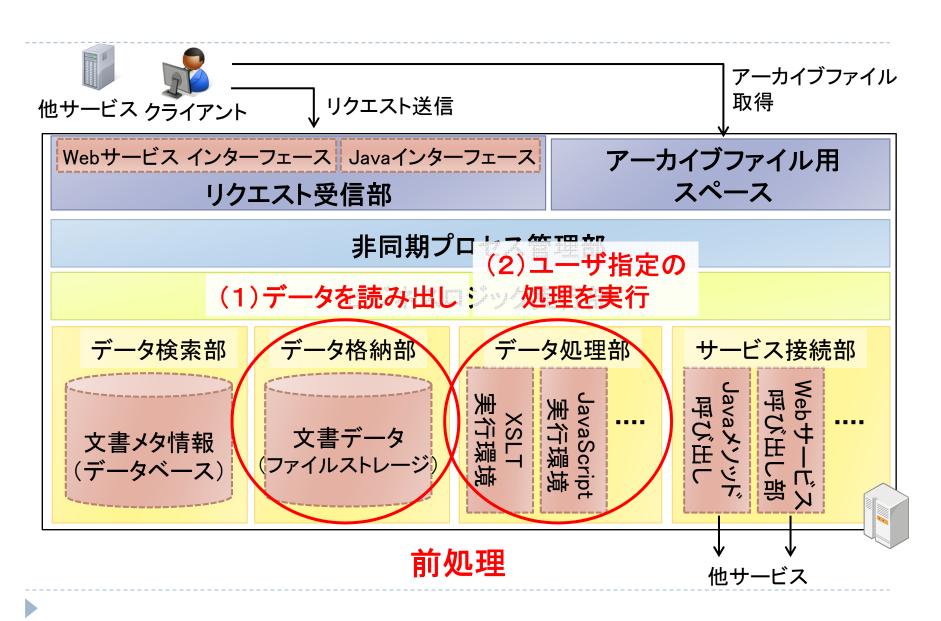
データインテンシブサービス

- データインテンシブサービス: 大規模データを扱うためのサービスのコンセプト
 - ▶ 事例に基づき、備えているべき基本的な機能を定義
 - データの分割/集約: 適切なデータセットを前もって用意
 - データの前処理: データが配置されたサーバ上で処理
 - ▶ 非同期転送: クライアントが任意のタイミングで結果データを取得
 - ▶ 更新通知: データセットの依存関係に基づき, 処理を再実行
 - ▶ 共有フレームワークとして実装し、相互運用性を向上
- 均質なハードウェアからなるクラスタでのデータ処理と異なり、 複数の部署・組織をまたいでデータ資産を活用
 - ▶ Hadoop等の既存のフレームワークが適さない
 - ▶ 機能的要件に注目して解決



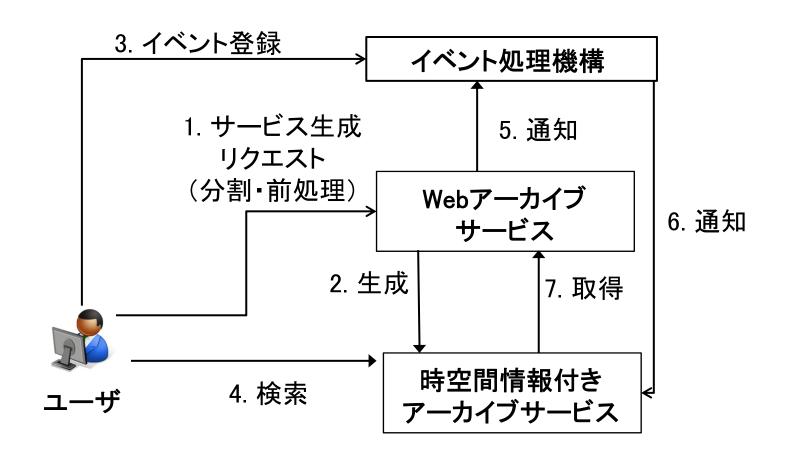




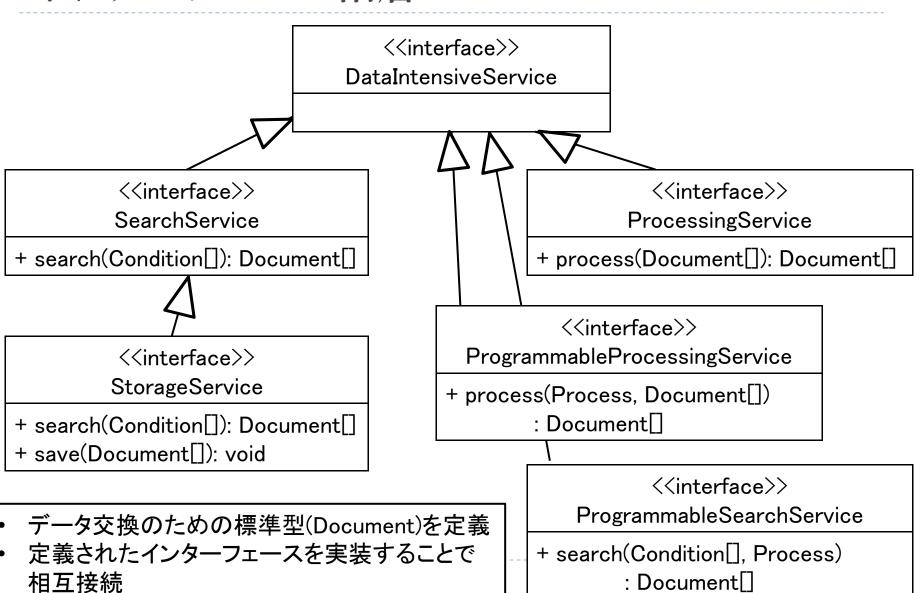


想定される運用例

▶ 時空間情報に基づくWebページ検索を提供するサービスを生成



プロトタイプ インターフェース階層



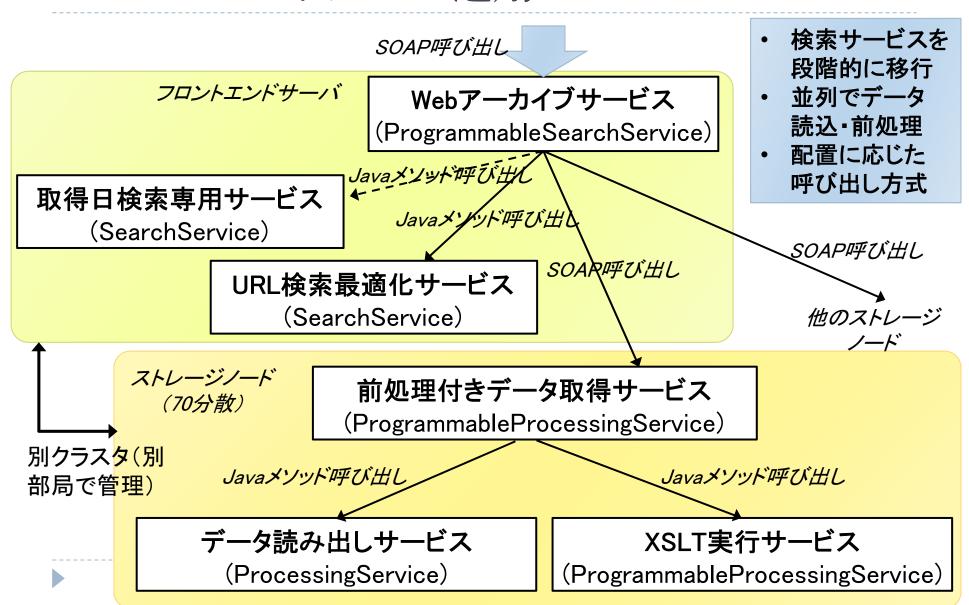
プロトタイプ インターフェース例

宣言	Document[] search(Condition[] conditions) (SearchServiceインターフェース)	
引数	conditions	検索条件. Condition型は以下の要素からなる. key: 検索条件に含める項目 value: 検索条件の値 operator: keyとvalueのマッチ操作
返値	検索条件に一致した文書集合. Document型は以下の要素からなるAttributeの集合とIDを持つ. attribute: 文書の属性名 value: 属性名に対応する属性値	
説明		索し、検索条件にマッチした文書集合を返す.

プロトタイプ インターフェース例

宣言	Document[] process(Process process,	
	Document[] documents)	
	(ProgrammableProcessingServiceインターフェース)	
引数	Process 各文書に適用される処理. Process型は以下の要素からなる. 処理には, 指定した言語で, Documentを引数に取り, Documentを返す関数を定義する. language: 処理の言語 body: 処理の記述	
	回ります。 処理対象の文書集合。 Document型は以下の要素を持つ属性の集合として定義される。 attribute: 属性名 value: 属性値	
返値	文書の処理結果.	
説明	与えた文書集合にユーザ指定の処理を適用する.	

Webアーカイブへの適用



まとめ

▶動機

- ▶ 大規模かつ多様なデータが増大
 - ▶ Webデータ, サイエンスデータ, etc.
- ▶ データ分析等の目的にアクセス手段が必要
- ▶ データインテンシブサービス: 大規模データを扱うためのサービスのコンセプトを提案
 - ▶ 事例に基づき、備えているべき基本的な機能を定義
 - 共有フレームワークとして実装し、相互運用性を向上
- ▶ プロトタイプを実装し、Webアーカイブに適用

ト今後の予定

- プロトタイプ実装の機能向上
- ▶ Webデータ・サイエンスデータの横断的利用